

1. 혼동 행렬 (Confusion Matrix) 이란?

모델이 실제 정답을 얼마나 맞혔고, 또 어떤 식으로 틀렸는지(혼동했는지) 보여주는 표

[예시]

총 100통의 메일이 있음. (실제 스팸 30통, 일반 메일 70통)

AI 차단기가 다음과 같이 분류했다고 가정함.

	실제 스팸 (Positive)	실제 일반 (Negative)
AI가 '스팸'이라 함 (Positive)	TP = 20 (정답!)	FP = 5 (오보)
AI가 '일반'이라 함 (Negative)	FN = 10 (놓침)	TN = 65 (정답!)

- TP (True Positive): 스팸을 스팸이라고 잘 맞힘 (20건)
- FP (False Positive): 일반 메일인데 스팸이라고 잘못 예측함 (5건) → "오보"
- FN (False Negative): 스팸인데 일반 메일이라고 놓침 (10건) → "미검출"
- TN (True Negative): 일반 메일을 일반 메일이라고 잘 맞힘 (65건)

2. 측정 기준 (Metrics)

① 정확도 (Accuracy)

전체 데이터 중 맞게 예측한 비율

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} = \frac{20+65}{100} = 0.85(85\%)$$

② 정밀도 (Precision)

모델이 "스팸이다!"라고 외친 것들 중 실제 스팸인 비율 (잘못된 스팸 처리를 줄이는 게 중요할 때 씬)

$$\text{Precision} = \frac{TP}{TP+FP} = \frac{20}{20+5} = 0.8(80\%)$$

의미: AI가 스팸이라고 가둔 메일 10통 중 8통만 진짜 스팸이고, 2통은 중요한 일반 메일일 수 있다는 뜻.

③ 재현율 (Recall / Sensitivity)

실제 스팸들 중 모델이 스팸이라고 골라낸 비율 (스팸을 한 통도 놓치고 싶지 않을 때 중요함)

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{20}{20+10} \approx 0.67(67\%)$$

의미: 전체 스팸 10통 중 6.7통만 잡고, 나머지는 내 받은 편지함으로 들어왔다는 뜻.

④ 특이도 (Specificity)

실제 일반 메일들 중 모델이 일반 메일이라고 맞힌 비율

$$\text{Specificity} = \frac{TN}{TN+FP} = \frac{65}{65+5} \approx 0.93(93\%)$$

⑤ F1-Score

정밀도와 재현율의 조화 평균임. 둘 중 하나가 너무 낮으면 점수가 확 깎임. 데이터가 불균형할 때(예: 스팸은 적고 일반 메일은 압도적으로 많을 때) 가장 신뢰하는 지표

$$F1-Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} = 2 \times \frac{0.8 \times 0.67}{0.8 + 0.67} \approx 0.73(73\%)$$

3. 요약 및 결론

- **정확도(85%)**는 높아 보일 수 있지만, **재현율(67%)**이 낮아 스팸을 많이 놓치고 있음.
- 만약 업무용 메일 시스템이라면, 중요한 메일을 스팸함에 넣으면 안 되므로 **정밀도**를 높이는 데 집중해야 함.
- 반면 암 진단 AI라면, 환자를 놓치면 안 되므로 **재현율**을 높이는 것이 최우선임.

요약:

정확도만 보지 말고, 내 모델이 '**오보(FP)**'를 내면 위험한지 '**미검출(FN)**'을 하면 위험한지에 따라 **정밀도와 재현율** 중 하나를 골라 집중해서 관리해야 함!