

암과 싸워 이기기 위한 파이토치 활용

9장에서 다루는 내용

- 커다란 문제를 잘게 쪼개서 해결하는 방법
- 난해한 딥러닝 문제의 제약사항을 살펴보고 구조와 접근 방법 결정하기
- 훈련 데이터 다운로드

이 장이 목표하는 바는 두 가지다. 하나는 2부의 전반적인 계획에서 출발해 이후 이어지는 각 장에서 다룰 내용의 규모와 범위에 대해 확실히 파악하는 것이다. 10장에서 우리는 데이터를 파싱하고 다루는 루틴을 구축해서 11장의 첫 번째 모델 훈련에서 사용할 데이터를 생성할 것이다. 이번 9장의 또 다른 목적은 이어지는 각 장에서 필요한 내용을 잘 준비하기 위해 프로젝트가 동작할 주변 환경에 대해 파악하는 것이다. 따라서 9장에서는 데이터 포맷, 데이터 소스, 그리고 우리 앞에 펼쳐진 문제 영역의 제약사항을 살펴볼 것이다. 앞으로 맞닥뜨리게 될 만만찮은 실제 딥러닝 프로젝트에서도 잘 적응하도록 이러한 작업에 익숙해지기 바란다.

9.1 사용 사례 소개

이 책의 1부에서 파악한 바와는 달리, 현실에서는 예상한 대로 일이 흘러가지 않는 경우가 흔하다. 따라서 이번 2부에서는 그런 경우에 다룰 수 있는 도구를 여러분에게 제공하려 한다. 모든 실패를 예측하거나 디버깅 기법을 일일이 설명할 수는 없어도, 여러분이 장애물을 만났을 때 최소한 막히지는 않도록 충분한 도움을 주고자 한다. 혹은 여러분이 수행하는 프로젝트의 성능이 생각보다 좋지 않을 경우 그다음에 무엇을 해야 할지 아무런 생각도 떠오르지 않을 암담한 상황에서 벗어나는 데 도움을 주고 싶다. 곧 여러분은, 시도해볼 아이디어가 많아져서 목록을 만들고 우선순위를 챙겨가며 도전하게 될 것이다!

이와 같은 아이디어나 기법들을 소개하려면 조금은 전문적인 상황 설정이 필요하다. 우리는 환자의 흉부 CT 스캔을 입력으로 받아서 그것만으로 악성 종양을 자동으로 탐지하는 설정을 골랐다. 실수가 필연적인 사람에 의한 영향보다는 기술적인 도전 과제에 집중하게 될 텐데, 엔지니어링 관점에서라도 2부는 프로젝트를 수행하기 위해 1부에서 했던 것보다 더 진지하고 구조적인 접근 방법이 요구된다.

노트

CT 스캔은 3차원 엑스레이로 단일 채널 데이터의 3차원 배열로 표현된다. 이에 관해서는 곧 자세히 다룰 예정이다.

이미 느꼈겠지만 이 장의 제목은 다소 시선을 끌기에 충분하고 의도적으로 과장한 면도 없지 않다. 구체적으로 말하자면 2부의 프로젝트에서는 사람 몸통의 3차원 CT 스캔을 입력으로 받아서 악성 종양이 의심되는 경우 해당 위치를 출력한다.

폐암의 조기 발견은 생존율에 큰 영향을 미치지만 모든 인구에 대해 포괄적으로 수동 판별을 해 내기는 쉽지 않다. 오늘날, 고도로 훈련된 전문가가 수행하는 데이터 판별은 세부적인 면까지 집중해야 하는 어려운 작업일 뿐만 아니라 암이 발견되지 않는 케이스가 대부분이다.

예컨대 건초 더미를 백 개쯤 쌓아두고 “이 중에 혹시 바늘이 있는지 찾아보세요”라고 요구하는 셈이다. 일일이 찾다가는 경고의 징후를 놓칠 수도 있으며, 특히 단서가 모호한 발병 초기 단계에는 더욱 그러하다. 인간의 두뇌는 이런 단조로운 작업에 적합하지 않다. 따라서 딥러닝 도입이 시급한 것이다.

이처럼 프로세스를 자동화하게 되면, 처음부터 더 많은 작업을 수행해야 하는 비협조적인 환경에 놓이게 될 것이며 마주칠 수 있는 문제에 대한 손쉬운 답을 찾기 어려워질 수도 있다. 하지만 이 책을 통해 우리는 함께 목표에 도달할 것이다! 2부를 끝내고 나면 여러분 스스로 선택한, 현실 세계의 미해결 문제에 대해 작업할 준비를 마치게 될 것이다.

이 책에서 우리는 몇 가지 이유로 꽤 중앙 감지 문제를 선택했다. 그중 가장 중요한 이유는 이 문제가 아직 미해결 과제라는 점이다. 이 점은 매우 중요한데, 파이토치를 사용해 최첨단 프로젝트를 효과적으로 처리할 수 있다는 점을 명백히 밝히고 싶기 때문이다. 또한 파이토치 프레임워크에 대한 신뢰를 높임은 물론이고, 개발자로서 여러분의 자신감도 고취시키고 싶다. 이 문제의 또 다른 장점이라면, 최근까지는 미제였지만 상당히 많은 팀이 도전 중이고 최근 들어 더욱 유망한 결과를 보인다는 점이다. 따라서 집단 지성이 발휘되어 곧 이 문제를 풀어낼 가능성이 크다. 그러므로 향후 수십 년간 해결하기 어려울 문제를 풀기 위해 시간을 낭비하는 일은 없을 것이다. 이 문제에 대한 높은 관심으로 이미 많은 고품질의 논문과 오픈 소스 프로젝트도 나와 있으며, 이를 통해 새로운 아이디어를 발굴해내고 영감도 얻을 수 있다. 우리가 만들어낸 해법을 꾸준히 개선해가는 과정에 관심이 있다면, 2부의 마무리 부분에서 큰 도움을 얻을 수 있을 것이다. 14장에서 관련 정보와 링크 몇 가지를 제공할 예정이다.

2부에서는 계속해서 폐 종양 탐지 문제에 집중하지만, 여기서 다루는 기술은 보편적이다. 어떤 프로젝트를 수행하든 훈련을 위해 데이터를 조사하고 전처리하며 어떻게 표현할지를 학습하는 것은 중요하다. 우리가 폐 종양이라는 특정 상황에 대한 전처리를 다루더라도 기본 전제는, 프로젝트의 성공적 수행을 위해 ‘우리는 무엇을 준비해야 하는가’일 것이다. 이와 마찬가지로, 훈련 루프를 설정하고, 올바른 성능 지표를 얻으며, 프로젝트 모델을 최종 애플리케이션으로 잘 연결하는 것은 모두 9장에서 14장까지 다룰 일반적인 기술이다.

노트

2부의 최종 결과물이 동작하더라도 출력 결과는 의학적으로 사용할 수 있을 만큼 정확하지 않을 수도 있다. 우리는 파이토치 교육의 동기 부여에 초점을 맞추는 뿐이지, 문제를 풀기 위해 온갖 수단을 동원하는 것에 목적을 두진 않는다.

9.2 대규모 프로젝트 준비

이번 프로젝트는 1부에서 배운 기술에 기반해 만들었다. 특별히 8장에서 다룬 모델 구축 내용은 직접적으로 연관되어 있다. 해상도를 낮추는 다운샘플링 뒤에 이어지는, 반복되는 컨볼루션층이 모델의 대부분을 채운다. 하지만 모델에서는 입력으로 3차원 데이터를 사용한다. 1부 후반부의 몇 개 장에 걸쳐 사용한 2차원 이미지 데이터와 개념적으로는 비슷하지만 파이토치 환경의 2차원에 대응하는 관련 도구는 더 이상 사용할 수 없다.

8장에서 컨볼루션 모델로 다룬 작업과 달리 2부의 작업은 모델 외의 부분에 얼마나 많은 노력이 들어가야 하는지와 관련되어 있다. 8장에서는 바로 사용 가능한 데이터셋이 있었고, 분류를 위한 모델에 데이터를 넣기 전에 데이터 조작은 거의 하지 않았다. 따라서 대부분의 시간을 모델 자체를 구축하는 데 집중했다. 하지만 앞으로 11장까지는 우리가 다룰 두 가지 모델 아키텍처 설계를 시작조차 하지 않을 것이다. 모델에 바로 꽂아 사용할 수 있는 훈련 샘플을 제공하는, 이미 구축된 라이브러리 형태의 표준 데이터가 없기 때문이다. 우리는 우리가 다룰 데이터에 대해 배우고 직접 구현도 해야 한다.

이 과정이 다 끝나더라도 CT 영상 데이터를 텐서로 변환해서 신경망에 넣어 다른 쪽에서 결과를 뽑아볼 수는 없다. 실세계에서 일어나는 일과 흡사하게 우리의 접근 방식은 제한된 데이터 접근성이나 한정된 연산 자원, 그리고 효과적인 모델을 설계하는 능력의 한계 등과 같은 교란 변수로 인해 생각보다 복잡해진다. 이 점은 프로젝트 아키텍처에 대한 개괄적인 설명을 할 때 명심해두기 바란다.

한정된 연산 자원을 고려하여 2부는 적절한 훈련 속도를 위해 최소 8GB 이상의 램을 갖춘 GPU가 필요하다. CPU에서 모델을 만들어 훈련시키면 몇 주는 걸릴 것이다!¹ GPU가 없는 경우를 위해 이 책의 14장에서 사전 훈련된 모델을 제공한다. 거기에 있는 결절 분석 스크립트는 아마 밤새도록 돌아갈 것이다. 이 책의 내용을 특정 서비스에 국한하고 싶지는 않지만, 이 책을 쓰는 시점에 코랩(<https://colab.research.google.com>)에서 무료 GPU 인스턴스를 제공하니 사용해볼 수 있다는 점에 주목하자. 파이토치도 이미 설치되어 있다! 그 외에 원본 훈련 데이터와 캐시 데이터, 그리고 훈련된 모델을 저장하기 위해 220GB의 디스크 공간이 필요하다.

노트

2부에서 보여줄 코드 예제 중 많은 부분의 복잡한 세부사항은 생략했다. 이 책에서는 예제 코드에 로그나 에러 처리, 예외 상황까지 덕지덕지 붙이기보다는, 설명을 돕기 위한 핵심 아이디어만 보여준다. 전체 코드는 이 책의 웹사이트(www.manning.com/books/deep-learning-with-pytorch)와 깃허브(github.com/deep-learning-with-pytorch/dlwpt-code)와 한국어판 도서정보 페이지(www.oniybook.co.kr/entry/pytorch)에서도 확인 가능하다.

그렇다. 우리는 이것이 다차원적이며 어려운 문제임을 파악하긴 했지만, 그다음엔 무엇을 해야 할까? 종양이나 잠재적인 암의 징후를 찾기 위해 CT 스캔 전체를 들여다보는 대신, 일련의 단순한 문제들을 풀고 이들을 조합하여 최종적으로 완성된 결과를 만들어내자. 공장의 조립 라인처럼 각 단계는 원자재(데이터)나 이전 단계의 결과물을 받아 몇 가지 처리를 한 후 다음 공정으로 전달한다. 모든 문제를 이런 식으로 풀 필요는 없지만, 문제를 덩어리로 나누고 분리하는 방법은 문제를 푸는 훌륭한 시작점이다. 막상 알고 보니 잘못된 접근이라 할지라도, 우리는 문제를 성공적으로 풀어내기 위해 각 덩어리에서 얻은 내용들로 어떻게 재구성하면 될지에 대한 좋은 아이디어를 배우게 될 것이다.

문제를 어떻게 잘게 나눌지에 대해 구체적으로 알아보기 전에 의학 분야에 대해 조금 알아둘 필요가 있다. 코드를 보면 무슨 일을 하는지 알 수 있긴 하지만 종양영상학에 대해 배워두면 그 일을 ‘왜’ 하는지도 알 수 있다. 분야를 막론하고, 해결해야 할 문제 영역에 대해 공부하는 것은 매우 중요하다. 딥러닝은 강력하지만 마법이 아니므로, 의학과 같은 중차대한 문제에 대해 맹목적으로 적용하다가 실패하고 말 것이다. 해당 분야에 대한 통찰력과 신경망의 동작에 대한 직관력을 잘 조합하여 제대로 훈련된 실험과 정제를 통해 정보를 얻음으로써, 우리는 쓸 만한 해결책에 가까이 다가설 수 있을 것이다.

9.3 CT 스캔이란

프로젝트를 깊게 파고들기에 앞서, CT(컴퓨터 단층 촬영) 스캔에 대해 잠시 알아보자. 이 책의 프로젝트에서는 주요 데이터 형식으로서 주로 CT 스캔 데이터를 다루게 된다. 따라서 CT 스캔이라는 데이터 포맷의 장단점과 기본적인 특성을 파악해야 제대로 활용할 수 있다. 앞에서 언급했던 핵심을 다시 정리해보자면, CT 스캔은 단일 채널의 3차원 배열로 표현되는 3차원 엑스레이 X-ray라 할 수 있다. 4장에서 살펴본 바대로, CT 스캔 데이터는 마치 흑백 PNG 이미지를 차곡차곡 쌓아놓은 것과 흡사하다.

복셀

복셀(voxel)이란 우리에게 친숙한 2차원 픽셀의 3차원 버전으로 생각하면 된다. 면적이 아닌 공간 용적을 담고 있으며(즉 용적 픽셀(VOLumetric piXEL)의 준말이다) 데이터 필드를 표현하기 위해 3차원 격자로 배열된다. 각 차원 내에서는 거리를 측정할 수 있다. 통상적으로 복셀은 정육면체인 경우가 흔하지만 이 장에서 우리가 다룰 복셀은 직육면체의 모양을 띈다.

의학 데이터 외에도 유체^{fluid} 시뮬레이션, 2차원 이미지로부터 재구성된 3차원 장면, 자율주행 자동차의 라이다^{LIDAR, light detection and ranging} 데이터 등에서 복셀 데이터를 볼 수 있다. 이러한 영역에는 저마다 특이한 상황이 존재한다. 우리가 사용할 API는 일반적인 여러 상황에도 적용 가능하지만, API를 좀 더 효과적으로 다루기 위해서는 데이터의 특성을 알아야 한다.

CT 스캔 내 각 복셀은 해당 위치에 있는 물체의 평균 질량 밀도를 나타내는 숫자 값을 가진다. 이 데이터들을 시각화하면 밀도가 높은 뼈나 금속 임플란트는 하얀색으로 보이고 밀도가 낮은 공기나 폐 조직은 검게 보인다. 지방이나 조직은 밝기가 다양한 회색으로 나타난다. 엑스레이와 유사하지만 본질적으로 다른 부분도 있다.

CT 스캔과 엑스레이의 근본적인 차이점은 엑스레이의 경우 (조직이나 골밀도 같은) 3차원적인 강도를 2차원 평면에 투영^{projection}한 것이지만 CT 스캔은 데이터의 3차원 형태를 보존한다는 점이다. 따라서 그림 9.1처럼 회색 음영 형태의 다양한 방법으로 데이터를 가공할 수 있다.




그림 9.1 사람 몸통의 CT 스캔 이미지. 위에서부터 피부, 장기, 척추, 그리고 환자를 받치고 있는 밀판을 볼 수 있다. (출처: 마인드웨이즈 CT 소프트웨어(Mindways CT Software) 이미지(<http://mng.bz/04r6>) / CC BY-SA 3.0(<https://creativecommons.org/licenses/by-sa/3.0/deed.en>) 조건하에 사용함)

노트

CT 스캔은 검체의 질량 밀도와 원자 번호의 함수 관계로 이뤄지는 방사선 밀도를 측정하여 나타낸다. 지금은 정확한 입력 단위가 무엇이든 간에 결국은 CT 데이터로 학습하면 되므로 단위는 구별할 필요가 없다.

이와 같은 3차원 데이터 표현을 통해 우리는 관심 없는 조직을 숨겨서 대상의 '내부를 들여다 볼 수' 있다. 예를 들어 그림 9.2와 같이 데이터를 3차원으로 나타내고(렌더링하고) 뼈와 폐 조직만 보이게 할 수 있다.




그림 9.2 갈비뼈와 척추, 폐 구조를 보여주는 CT 스캔

CT 스캔은 엑스레이보다 구하기가 훨씬 더 어렵다. 그림 9.3과 같은 의료 장비가 있어야 하는데 수십억 달러에 달하는 고가인 데다가 전문 운영 인력이 필요하기 때문이다. 대부분의 병원이나 규모가 큰 클리닉에 CT 스캐너가 있긴 하지만 엑스레이 장비처럼 흔하지는 않다. 여기에 환자의 개인정보 보호 규제까지 생각하면 누군가가 열심히 모아서 정리해놓지 않는 한 CT 스캔을 구하기는 여간해선 쉽지 않다.



그림 9.3 CT 스캐너 안에 환자가 있는 사진에 박스 모양을 그려넣었다. 사진과 달리 일반적으로 환자가 장비 안에 들어갈 때는 평상복을 입지 않는다.

CT 스캔 데이터에 해당하는 부분을 그림 9.3에 박스로 그려 놓았다. 환자를 받치고 있는 침대가 앞뒤로 움직이면 스캐너는 환자의 단층 사진을 여러 장 만들어 박스를 채워간다. 도넛 모양을 한 스캐너의 중앙 안쪽의 어두운 원형 띠 부분이 실제 이미지 처리 장비가 위치한 곳이다.

CT 스캔과 엑스레이의 또 다른 차이점은 데이터가 디지털 포맷이라는 점이다. CT라는 용어는 컴퓨터 단층촬영^{computed tomography}(https://en.wikipedia.org/wiki/CT_scan#Process)의 약어다. 즉 스캔 과정의 원본 출력은 사람이 육안으로 구별할 만한 형태가 아니라서 컴퓨터를 사용해 재 해석해야 한다. 스캔 시 CT 스캐너 설정에 따라 출력 데이터는 크게 달라진다.

적절한 정보가 될지 모르겠지만 그림 9.3에서 살펴볼 수 있는 것으로 CT 스캐너가 머리부터 발에 이르는 축을 따라 거리를 측정하는 방법은 신체의 다른 두 가지 축과는 다르다는 사실을 알 수 있다. 환자는 실제로 축을 따라 이동한다! 이를 통해 복셀은 정육면체가 아님을 알 수 있고 (또는 적어도 왜 아닌지 추측할 수 있으며), 이는 12장에서 데이터를 만져가며 다룰 때와 동일한 경우다. 이런 상황은 우리가 해당 분야를 이해하는 것이 왜 효과적인 해결안을 선택하는 데 도움이 되는지를 설명하는 적절한 예가 되기도 한다. 프로젝트를 시작하기 전에 데이터의 세부사항을 구체적으로 조사할 필요가 있다.

9.4 프로젝트: 엔드투엔드 폐암 진단기

CT 스캔에 대한 기본을 알았으니 프로젝트 구성에 대해 생각해보자. 디스크의 대부분은 밀도 정보를 가진 CT 스캔의 3차원 배열을 저장하는 데 사용할 것이고 우리의 모델은 주로 이 3차원 배열 부분에 해당하는 여러 단면을 사용한다. 우리는 흉부 CT 스캔 조사부터 환자에게 폐암 진단을 내리기까지 총 5가지 주요 단계를 거친다.

그림 9.4에 그려진 엔드투엔드^{end-to-end} 솔루션은 CT 데이터 파일을 읽어서 CT 인스턴스를 만든 후 전체 3차원 스캔 데이터를 담고 세그멘테이션^{segmentation}(관심있는 복셀을 표시하기)을 수행하는 모듈과 결합한 후 추려진 복셀을 작은 덩어리로 나누어 결절^{nodule}로 간주될 만한 것을 찾는다.




그림 9.4 전체 흉부 CT 스캔을 받아 환자에게 악성 종양이 있는지 여부를 판단하는 엔드투엔드 프로세스

결절의 위치 정보는 CT 복셀 데이터 뒤에 붙어 일종의 후보가 되고 이 후보들은 결절을 분류하는 모델에 의해 애초부터 실제 결절인지, 그리고 최종적으로 악성이 될지 여부를 조사하게 된다. 악성 여부를 판별하는 후자의 작업은 특히 어렵다. 악성 종양은 CT 영상만으로는 드러나지 않기 때문이다. 하지만 어디까지 할 수 있을지는 두고 볼 일이다. 마지막으로, 각각의 결절별 분류 결과는 환자 진단 결과로 병합할 수 있다.

결절

증식하는 세포로 이뤄진 조직 덩어리를 종양(tumor)이라고 한다. 종양은 양성(benign) 또는 악성(malignant)으로 나뉘며, 악성일 경우 암(cancer)라고도 한다. 폐에 있는 작은 종양(수 밀리미터에서 몇 센티미터)까지의 종양을 폐 결절(lung nodule)이라고 한다. 폐 결절의 약 40%는 악성인 것으로 알려져 있다. 따라서 최대한 초기에 잡아내는 것이 매우 중요하며, 이는 우리가 이 책에서 살펴보게 될 의학 영상 이미지에 달려 있다.

구체적으로 할 작업은 다음과 같다.

1. 원본 CT 스캔 데이터를 파이토치로 사용할 수 있는 형태로 읽어들이는다. 원본 데이터를 파이토치가 사용할 수 있는 형태로 넣는 것이 프로젝트에서 당면한 첫 번째 작업이다. 이 과정은 2차원 이미지에서는 다소 덜 복잡하며, 이미지 데이터가 아니라면 훨씬 더 간단하다.
2. 세그멘테이션^{segmentation}이라는 기술 구현을 위해 파이토치를 사용하여 폐의 잠재적 결절에 해당하는 복셀을 찾는다. 이는 히트맵^{heatmap}을 작성하는 것과 유사한데, 3번째 단계의 분류기^{classifier}에서 사용한다. 이 작업으로 관심 없는 해부학적 부위(위에 폐암이 존재할 수는 없으니)는 무시하고 폐 내부의 잠재적 종양에 더 집중할 수 있다.

일반적으로 학습 중에는 단일한 작은 작업에 집중하는 게 최선이다. 경험상, 더 정교하고 복잡한 모델이 최상의 결과를 보여주는 경우가 있다(2장에서 살펴본 GAN 게임처럼). 하지만 시작부터 이런 모델을 설계하려면 기본 빌딩 블록에 대한 수준급의 숙련도가 필요하다. 뛰기에 앞서 먼저 걷는 것부터 시작하자.

3. 관심 있는 복셀들을 덩어리(즉 후보 결절)로 묶는다(결절에 대해서는 그림 9.5를 참고하자). 우리가 만든 히트맵에서 각 핫스팟의 개략적인 중심부를 찾는 과정을 진행한다. 각각의 결절은 인덱스가 부여되며 중심부에서 시작하는 열과 행으로 위치를 알 수 있다. 이렇게 제약을 가해 단순해진 문제를 최종 분류기에 전달한다. 복셀 그룹화가 직접적으로 파이토치를 요구하지 않아서 별도 단계로 만들었다. 여러 단계로 문제를 해결하면 딥러닝이 필요하지 않은 단계는 이처럼 딥러닝이 필요한 큰 단계 사이를 연결하는 아교 역할을 한다.
4. 3차원 컨볼루션을 사용하여 각 후보 결절에 대해 실제 결절인지 아닌지로 분류한다. 이는 8장에서 다룬 2차원 컨볼루션 개념과 흡사하다. 후보 구조로부터 종양 여부를 결정하는 특성은 종양 진단에 국한된 문제다. 따라서 입력 데이터를 걸러내는 것과, 너무 걸러내다가 중요한 정보까지 버려지는 것 사이에서 균형을 잡을 필요가 있다. 이와 같이 범위를 제한하면 각각의 작업 단위가 줄어들기 때문에, 문제 해결이 필요할 때 확인해야 할 내용이 줄어들어 좋다.

5. 각 결절별로 분류한 결과를 종합하여 환자를 진단한다.

이전 단계의 결절 분류기와 비슷하게, 결절이 양성인지 악성인지를 영상 데이터에만 의존하여 판별해볼 것이다. 결절별로 악성 예측을 구한 후 이들의 최댓값을 사용하는 방식으로 하나라도 악성이 예측된 경우, 해당 환자는 암 소견을 보인다고 진단한다. 그 외의 프로젝트라면 개별 예측에 대해 파일 점수 집계용으로 또 다른 합산 방식을 사용할지도 모른다. 지금은 “의심스러운 점은 없는가?”를 알아보는 과정이므로 단순히 최댓값을 집계하는 것이 좋다. 만일 ‘조직 타입 A와 B의 비율’ 같은 정량적인 정보를 구한다면 최댓값 대신 평균을 사용할 수도 있다.

그림 9.4는 필요한 모든 모델을 이미 완성하고 훈련한 후의 시스템 전반에 걸친 최종 경로를 묘사하고 있다. 관련 모델을 훈련하기 위해 필요한 실제 작업은 각 단계를 구현해가면서 구체적으로 설명할 것이다.

3단계와 4단계에서 훈련을 위해 사용하는 데이터는 사람이 확인하고 표기한 정답을 제공한다. 그래서 2단계와 3단계(각 복셀을 확인하고 결절 후보군으로 묶는 것)를 4단계(결절 후보 분류)와 완전히 다른 거의 별개의 프로젝트로 취급할 수 있다. 전문가들이 직접 데이터에서 결절의 위치를 표시했기 때문에 2단계와 3단계, 또는 4단계를 순서에 상관없이 개별로 진행할 수 있다.

거인의 어깨 위에서

이와 같은 5가지 단계를 사용하는 것은 마치 거인의 어깨 위에 서 있는 것과 유사하다. 왜 그러한지는 14장에서 자세히 다룰 예정이다. 문제를 풀기 위해 이러한 프로젝트 구조가 왜 잘 동작하는지를 굳이 우리가 알아야 할 이유는 없지만, 비슷하게 만들어서 성공적인 결과를 보인 다른 사례들에 우리는 의탁하게 된다. 다른 문제 도메인으로 전환할 때 실행 가능한 접근법을 찾으려는 실험을 해보자. 하지만 동시에, 해당 분야에서의 과거 노력으로부터, 그리고 유사한 영역에서 효과가 있었으며 잘 전환될 만한 것들을 발견한 이들로부터 항상 배우려고 노력해보자. 외부로 눈을 돌려 다른 사람들은 어떤 연구를 했는지 찾아보고 그 결과를 벤치마크 자료로 사용하라. 그리고 아무것도 모른 채로 다른 이의 코드를 가져와 돌려보는 일은 없어야 한다. 스스로 진도를 내고자 결과를 사용한다면 돌리고 있는 코드를 완전히 이해해야 하기 때문이다.

우리는 1단계로 데이터를 읽어들이고 후 2단계와 3단계를 구현하기에 앞서 바로 4단계로 넘어갈 것이다. 8장에서 다룬 것과 비슷한 접근 방식으로 선형 분류기에 넣기 전에 다중 컨볼루션층과 풀링층을 통해 공간 정보를 누적하는 4단계를 거치고 난 후, 다시 2단계와 3단계로 돌아와 구현할 예정이다. 분류 모델을 조작할 단계가 되면 2단계의 세그멘테이션 작업을 시작할 수 있다. 세그멘테이션은 다소 복잡한 주제이기 때문에, CT 스캔이나 악성 종양에 대한 기본 지식을 동시에 다루는 대신 세그멘테이션을 먼저 알아 볼 것이다. 암 진단 부분은 관련성이 높은 분류 문제를 다룰 때 자세히 살펴볼 것이다.

갑자기 문제의 한복판에서 시작하는 방식이 혼란스럽게 느껴질지도 모르겠다. 1단계부터 시작해서 순서대로 진행하는 것이 직관적으로는 이해하기 편하다. 하지만 문제를 나누어 각 단계를 독립적으로 작업하면 솔루션의 모듈화를 독려할 수 있으므로 유용하다. 부가적으로 소규모 팀 내에서 구성원 간에 작업을 분배하기도 쉽다. 임상 작업자 입장에서든 의심스러운 결절이 있을 때에만 보여주는 시스템이 바이너리 진단 결과 하나를 통으로 제공하는 것보다는 낫다. 솔루션을 모듈화하면 다양한 사용 사례에 적용할 때에도 처음부터 끝까지 통으로 되어 있는 단일 시스템보다 더 쉽다.

각 단계를 구현해가면서 꽤 종양에 대해 구체적으로 들여다보고 CT 스캔의 세부 내용에 대해서도 자세히 설명할 예정이다. 파이토치에 대한 책치고 필요 이상으로 주제에서 벗어난 것으로 보일 수는 있겠으나 이를 통해 여러분은 문제 영역에 대한 직관력을 키울 수 있을 테므로 이해하기 바란다. 가능한 모든 솔루션과 접근법은 너무나 다양해서, 효과적으로 코드를 작성하고 훈련시키며 평가하기에는 어려우므로 먼저 직관력을 키울 필요가 있다.

(이 책을 다 읽고 나서) 다른 프로젝트를 하게 되더라도 여전히 데이터나 문제 도메인에 대해 조사해야 한다. 만약 여러분이 위성지도 제작에 관심이 있다면 다음 프로젝트는 궤도에서 찍은 지구 이미지를 사용해야 할 것이다. 수집한 파장에 대해 물어봐야 할 수도 있다. 일반 RGB 이미지만 있을 땐까? 아니면 특이한 정보가 필요할까? 적외선이나 자외선이 필요할지도 모른다. 여기에 하루 중 몇 시에 촬영했는지에 따라 정보에 영향을 줘줄 수도 있고, 이미지에서 나타나는 위치가 위성 바로 아래쪽이 아니라서 그림이 왜곡됐을 수도 있으며, 이미지 보정이 필요할 수도 있다.

여러분이 하게 될 가상의 어떤 프로젝트의 데이터 타입이 동일하게 유지된다 하더라도 데이터가 다루는 영역은 다르기 때문에 전혀 다르게 진행해야 할 수도 있다. 자율주행차용 카메라 출력은 여전히 2차원 이미지를 다루지만 복잡도나 주의할 점은 현저히 다르다. 예를 들어 위성지도 사진의 경우에는, 카메라에 햇살이 비치거나 렌즈에 흙이 묻을 일을 전혀 고민할 필요가 없다.

잠재적인 최적화나 개선을 피하려면 데이터에 대한 직관력을 활용할 수 있어야 한다. 이런 점은 딥러닝 프로젝트에서 일반적으로 요구되는 것으로, 2부에서도 직관력을 활용하는 연습을 할 것이다. 지금 우리가 접근하려는 방식이 직관적으로 괜찮은가? 너무 복잡해보이지는 않는가?

9.4.1 신경망이 동작할 때까지 데이터를 던져넣을 수 없는 이유

지금까지 내용을 읽고 “이건 8장이랑 너무 다른데!”라고 느낄 수도 있다. 동시에 왜 두 개의 분리된 모델 아키텍처가 있고, 또 전체 데이터 흐름은 왜 이렇게 복잡한지 궁금할 수도 있다. 접근 방식이 8장과는 다른 데는 한 가지 이유가 있다. 자동화하기 어려운 문제라서 아직 사람들이 제대로 파악하지 못한 상태이기 때문이다. 이와 같은 난해함은 결국 복잡함으로 이어진다. 여러 연구 집단이 이 문제를 확실하게 풀었다면 아마 바로 사용 가능한 라이브러리 패키지가 있어서 바로 써도 되겠지만 아직은 그렇지 않다.

그렇다면 왜 이렇게 어려운 걸까?

음, 우선, “이 환자에게 악성 종양이 있는가?”라는 질문에 답하기에 대부분의 CT 스캔은 근본적으로 별로 흥미롭지 않은 데이터다. 직관적으로 생각해 보면, 거의 대부분의 환자의 몸은 건강한 세포로 이뤄져 있기 때문이다. 악성 종양이 있는 경우를 봐도 CT에 있는 99.9999%의 복셀은 암 세포가 아니다. 비율로 따지면 고해상도TV(HDTV) 어딘가에 색이 이상한 2개 픽셀 정도에 해당한다. 결절을 찾는 일은 책으로 가득한 서가에서 철자가 틀린 단어 하나를 찾는 것과 비슷하다.

그림 9.5의 3개 사진에 보이는 흰색 점 중에서 결절로 판정된 점이 어떤 것인지를 육안으로 구별할 수 있는가?²

치밀 조직에서 적절한 부분을 찾는 데 힌트가 필요하다면 인덱스, 행, 열 값을 사용할 수 있다. 하지만 이런 식으로 주어진 이미지만을 가지고(인덱스, 행, 열 정보 없이!) 종양에 해당하는 특성을 구별해낼 수 있을까? 스캔 데이터에서 관련 부분만 단면으로 만든 세 개의 이미지가 아니라 3차원 스캔 전체가 주어진다면?

노트

종양 위치를 못 찾더라도 걱정하지 말자! 우리는 이 데이터가 얼마나 미묘한 차이를 가지는지 설명하기 위함이다. 예제에서 시각적으로 식별하기 어렵다는 것만 이해한다면 충분하다.




그림 9.5 비전문가의 눈에는 1000개의 종양처럼 보일 수 있는 CT 스캔. 전문가는 이 사진에서 정확히 하나의 결절을 발견했다. 나머지는 혈관이나 병변 등의 문제가 없는 정상적인 해부학적 조직이다.

아마 다른 곳에서 이런 식으로 물체를 발견하고 분류하는 엔드투엔드 접근 방식이 일반적인 비전 작업에서 매우 성공적이라는 얘기를 들었을 것이다. 토치비전^{TorchVision}에는 Fast R-CNN이나 Mask R-CNN 같은 모델이 포함되어 있지만, 이러한 모델은 전형적으로 수십만 건의 이미지로 훈련되었으며, 이때의 데이터셋은 제한된 수량의 샘플을 가지는 특이한 클래스인 경우도 아니다. 반면 우리가 사용할 프로젝트 구조는 적당히 더 많은 양의 데이터가 있을 때 제대로 동작한다. 따라서 마치 건초 더미는 무시하며 잃어버린 바늘을 찾기 위한 단서를 학습할 때까지 신경망에 임의의 많은 데이터를 던져넣는 것은 이론적으로 가능하다. 하지만 이를 위해 신경망이 적당하게 훈련되도록 기다려야 하는 긴 시간과 수집해야 하는 막대한 데이터 양은 실용적인 수준을 넘어서므로 추천하지 않는다. 이는 성능도 현저히 떨어지는 결과이기 때문에 최선의 방법도 아니며, 이런 방식으로 돌리려면 대부분의 독자들은 필요한 연산 자원을 확보하지도 못할 것이다.

최선의 방법은 우리처럼 엔드투엔드 방식에서 데이터를 더 잘 통합할 수 있는 검증된 모델 설계를 검토하는 것이다.³ 이와 같이 검증된 정교한 모델들은 고품질의 결과를 만들어낼 수 있지만 최선은 아니다. 왜냐면 이 모델 이면의 설계 결정을 이해하려면 먼저 기본 개념을 파악해야 하기 때문이다. 따라서 동일한 근본 원리를 가르치기 위해 고급 모델들은 결국 추천할 만한 후보가 되지 못한다.

그렇다고 해서 우리의 다단계 설계가 최적의 접근 방법이라는 할 수는 없다. ‘최적’이라는 것은 각 접근 방법들을 모아놓고 비교 평가할 때 사용하는 상대적인 개념이기 때문이다. 프로젝트를 수행할 때에는 목표가 다양할 수 있듯이, ‘최적’의 접근 방법도 다양하다. 목표가 무엇인지에 따라 우리의 다단계 프로세스에는 몇 가지 단점도 있다.

2장에서 다룬 GAN을 생각해보자. 우리는 두 개의 신경망이 상호 동작하며 오래된 거장 예술가의 위작을 만드는 목표를 세웠다. 예술가 역할의 신경망은 후보 작품을 만드는 일을 맡고, 비평가 역할의 신경망은 작품을 비평하며 예술가에게 개선할 부분에 대해 피드백을 제공했다. 기술적인 용어로, 모델의 구조는 마지막 분류기(위작인가 진품인가)로부터 프로젝트의 앞부분(예술가 역할 부분)으로 기울기를 역전파할 수 있었다.

문제를 풀기 위한 우리의 접근 방식은 최종 목표에 맞는 최적화로 엔드투엔드 기울기 역전파를 사용하지 않을 것이다. 대신 문제의 부분 부분을 최적화하는 방식으로 동작한다. 우리의 세그멘테이션 모델과 분류 모델이 서로 협력하게끔 훈련된 것이 아니기 때문이다. 따라서 솔루션의 효율성이 최대가 되지는 않지만, 배우는 입장에서는 더 낫다고 생각한다.

또 한 번에 한 단계씩 초점을 맞추면, 이 안에서 요구하는 기술에만 집중할 수 있는 효과도 있다. 두 개의 모델 각각은 정확하게 하나의 작업을 수행하는 데 집중한다. 방사선 전문의가 CT 단면을 하나하나 검토하는 것처럼, 범위가 정리되어 있으면 작업을 훈련시키기도 쉬워진다. 그리고 우리는 데이터를 자유롭게 조작할 수 있는 도구도 제공하고자 한다. 특정 위치에 대해 상세하게 볼 수 있는 확대 기능이 있다면, 전체 이미지를 한 번에 봐야 할 때보다 모델을 훈련시킬 때 전체적인 생산성이 크게 좋아진다. 세그멘테이션 모델은 전체 이미지를 사용하게 되어 있지만 이를 잘 구성해서 분류 모델은 관심 영역을 확대한 데이터를 사용하게 할 예정이다.

3단계의 그룹화는 데이터를 만들고, 4단계의 분류는 이 데이터를 사용하는데, 여기서 데이터란 그림 9.6의 이미지처럼 종양에 대한 연속적인 CT 단면을 말한다. 이 그림의 이미지는 종양(판별하기 어렵거나 잠재적으로 악성일 가능성이 있는 종양)을 확대한 것으로, 우리는 4단계의 모델이 이 이미지를 식별할 수 있도록 훈련시킬 것이다. 그리고 5단계의 모델은 이 데이터가 양성인지 악성인지를 분류한다. 훈련되지 않은 눈(훈련되지 않은 컨볼루션 신경망)으로 보기에는 별다른 특징이 없는 덩어리에 지나지 않겠지만, 이 샘플에서 악성의 징후가 될 만한 경고성 흔적을 발견하는 것은 이전에 우리가 살펴본 전체 CT를 들여다보는 것보다는 훨씬 더 간추려진 문제임에 틀림없다. 다음 10장의 코드는 그림 9.6에서처럼 확대된 결절 이미지를 만들어낼 것이다.




그림 9.6 그림 9.5의 CT 스캔에서 종양 부분을 잘라낸 여러 단면의 확대 이미지

우리는 10장에서 데이터를 읽는 1단계를 수행하고, 11장과 12장에서 결절을 분류하는 문제에 집중할 것이다. 그리고 나서 13장에서는 다시 2단계(결절 후보들을 찾아 세그멘테이션하기)로 돌아오고 14장에서는 3단계(그룹화)와 5단계(결절 분석 및 진단)를 모두 합쳐 엔드투엔드 프로젝트로 완성하여 2부를 마무리할 것이다.

노트

CT의 표준 렌더링은 상체를 영상 맨 위에 배치하지만(기본적으로 머리가 위쪽을 향함) CT 단면의 배치 순서는 그 반대로 발쪽이 먼저다. 이 때문에 이를 고려해서 뒤집어 주지 않으면 맵플롯립(Matplotlib)은 이미지를 거꾸로 렌더링한다. 우리 모델은 상하 반전에는 관심이 없으므로 원본 데이터와 모델 사이의 코드 구현을 복잡하게 하지 않고, 다만 이미지를 렌더링하는 코드에서만 제대로 된 방향을 맞추기 위해 뒤집는 부분을 넣는다. CT 좌표계에 대한 자세한 정보는 10.4절을 살펴보라.

앞서 살펴본 우리 시스템의 전체 모습을 그림 9.7에서 다시 확인해보자.




그림 9.7 환자의 악성 종양 여부를 판단하기 위해 흉부 CT 스캔을 엔드투엔드로 처리하는 과정

9.4.2 결절이란 무엇인가

앞에서 데이터를 효과적으로 사용하려면 먼저 잘 이해해야 한다고 설명했듯이 암과 종양영상학에 대해서도 배워둘 필요가 있다. 우리가 알아야 할 마지막 핵심은 결절^{nodule}⁴이 무엇인지에 대한 것이다. 간단히 말해, 결절이란 글자 그대로 누군가의 폐 내부에서 나타날 수 있는 무수한 돌기나 덩어리를 말한다. 결절에 따라, 환자의 건강 면에서 문제가 되는 것도 있지만 그렇지 않은 것도 있다. 정확한 정의⁵에 따르면, 결절의 크기는 3센티미터 이하여야 하며, 이보다 클 경우에는 폐 종괴^{lung mass}라 부른다. 다만 이 기준은 임의적이고 3센티미터보다 크든 작든 동일한 코드 경로를 사용하게 되므로, 편의상 우리 책에서는 동일한 해부학적 구조라면 모두 결절이라고 부르고자 한다. (폐에 있는 일종의 작은 덩어리인) 결절은 양성 종양 또는 (암이라고도 부르는) 악성 종양으로 밝혀질 수 있다. 방사선학 관점에서 결절은 감염이나 염증, 혈액 공급 이상, 기형적 혈관, 종양 이외의 질환 등 다양한 원인으로 유발된 덩어리라 할 수 있다.

여기서 중요한 핵심은, 우리가 찾아내려는 암은 항상 결절의 형태를 띠는 것이며, 이 결절은 밀도가 매우 낮은 폐 조직에 매달려 있거나 폐 벽에 붙어 있을 것이라는 점이다. 따라서 우리의 분류기는 모든 조직을 검사할 필요 없이 결절에만 집중하면 된다. 이런 식으로 예상 입력 범위를 좁히면 분류기가 작업을 학습하는 데 도움이 된다.

이 부분은 딥러닝에서 보편적으로 사용하는 기술이기도 하다. 다만 잘 알고 사용하기를 바란다.⁶ 이런 방법으로 도움을 얻기 위해서는 자신이 적용하려는 분야에 대한 이해도가 높아야 한다.

그림 9.8에서는 악성 결절의 전형적인 모양을 볼 수 있다. 이 그림에서처럼 크기가 큰 결절도 있지만, 우리가 관심을 기울일 결절의 최소 크기는 겨우 몇 밀리미터에 불과하다. 이 장의 초반부에서 설명했던 것처럼 가장 작은 결절은 대략 전체 CT 스캔의 수백만 분의 일 정도로 매우 작다. 환자에게서 발견된 결절의 대략 절반 이상은 악성이 아니다.⁷









그림 9.8 악성 결절을 다른 결절과 비교시 시각적 차이를 보여주는 CT 스캔

9.4.3 데이터 소스: LUNA 그랜드 챌린지

우리가 보는 CT 스캔은 LUNA^LUng Nodule Analysis(폐 결절 분석) 그랜드 챌린지에서 가져온 것이다. LUNA 그랜드 챌린지는 (다량의 폐 결절이 있는) 환자의 CT 스캔 자료를 고품질로 레이블 작업한 공개 데이터셋으로서 데이터 분류기 성능에 대한 공개 랭킹을 제공한다. 연구나 분석을 위해 의료 데이터셋을 공개하는 문화가 있다. 기관 간의 공식적인 연구 계약을 체결하지 않고도, 연구원은 이렇게 공개된 데이터를 사용하고 다른 것과 결합할 수도 있으며, 데이터에 대한 새로운 작업을 수행할 수 있다(물론, 일부 데이터는 비공개로 유지된다). 루나 그랜드 챌린지의 목적은 선두 팀들의 순위권 경쟁을 좀 더 수월하게 만듦으로써 결절 탐지력 향상을 추구하고자 함이다. 프로젝트 팀은 (제공되는 데이터셋에 해당하는) 표준화된 기준^{criteria}에 대해 자신들의 탐지 방법이 효과적인지 테스트할 수 있다. 공개 랭킹에 들어가려면 팀은 프로젝트의 구조와 훈련 방법 등을 기술한 과학 논문을 제출해야 한다. 이는 프로젝트 발전을 위한 추가적인 아이디어와 동기 부여를 제공하는 원천이 된다.

노트

다양한 스캔 장비와 처리 프로그램 간의 특이한 방식의 차이로 인해, '실제 현장에서 사용되는' 대부분의 CT 스캔은 처리하기가 엄청나게 복잡하다. 예를 들어 어떤 스캐너 같은 경우는 복셀 밀도가 음의 값으로 설정되어 CT 스캔 영역이 대상 영역 밖으로 지정되기도 한다. 동시에 CT 스캔 데이터 역시 스캐너의 다양한 설정에 따라 아주 민감하게 혹은 매우 거칠게 잡히기도 한다. LUNA 데이터는 일반적으로 깨끗한 편이지만, 만일 다른 데이터 소스를 다루게 된다면 이런 문제들을 고려해야 한다.

이 책에서 우리는 LUNA 2016 데이터셋을 사용한다. LUNA 사이트(<https://luna16.grand-challenge.org/Description>)에는 두 종류의 도전 기록을 볼 수 있다. 하나는 '결절 탐지^{NDET}, nodule detection'로 대략 우리의 첫 번째 세그멘테이션 단계에 해당하며, 다른 기록은 '거짓 양성 감소^{FPRED}, false positive reduction'로 우리의 3번째 분류 단계와 유사하다. 사이트를 보면 '잠재적 결절의 위치'에 대한 내용이 있는데, 이는 우리가 13장에서 다룰 내용과 유사하다.

9.4.4 LUNA 데이터 다운로드

프로젝트의 세부 작업을 진행하려면 먼저 데이터를 얻는 방법을 알아야 한다. LUNA 데이터는 대략 60GB 정도의 압축된 데이터로, 인터넷 속도에 따라서 내려받는 시간에 차이가 있을 것이다. 압축을 풀면 120GB의 공간을 차지한다. 이외에 추가로, CT 전체 데이터를 읽는 대신 필요한 부분만 읽도록 데이터를 작은 덩어리로 나눠둔 100GB 정도의 캐시 공간이 필요하다.⁸

<https://luna16.grand-challenge.org/download>로 가서 이메일이나 구글 OAuth 로그인을 하면 제노도^{Zenodo} 데이터를 내려받을 수 있는 다운로드 링크와 아카데미용 토렌트 링크를 볼 수 있다. 두 링크의 데이터는 동일하다.

팁

luna.grand-challenge.org 도메인에는 아직 데이터 다운로드 링크가 없다. 다운로드 페이지를 찾기 어렵다면 luna.가 아닌 luna16.으로 시작하는 도메인을 방문해보라.

우리가 사용할 데이터는 10개의 서브셋으로 구성되어, 각기 subset0부터 subset9까지의 이름을 가진다. 각각의 압축을 풀면 `code/data-unversioned/part2/luna/subset0` 같은 개별 서브 디렉토리가 나타날 것이다. 리눅스라면 7z 압축 해제 도구가 필요할지도 모른다(우분투는 `p7zip-full` 패키지를 제공한다). 윈도우 사용자는 7-Zip 웹사이트(www.7-zip.org)에서 압축 해제 프로그램을 받을 수 있다. 다른 압축 해제 유틸리티로는 압축을 풀지 못할 수도 있다. 오류가 발생할 경우 해당 압축 프로그램이 풀 버전인지를 확인해보자.

추가로 `candidates.csv`와 `annotations.csv` 파일도 필요하다. 독자 여러분의 편의를 위해, 이 책의 웹사이트와 깃허브 디렉토리에 파일을 올려놓았다. `code/data/part2/luna/*.csv`를 찾아보면 되고 데이터 서브셋을 받았던 곳에서도 내려받을 수 있다.

노트

디스크에 최대 220GB 공간이 없다면 열 개의 서브셋 중에 한두 개 예제만 실행 가능할 것이다. 훈련셋이 적을수록 모델 성능은 훨씬 떨어지겠지만 예제를 아예 실행할 수 없는 것보다는 낫다.

`candidates` 파일과 한 개 이상의 서브셋 파일을 내려받아 압축을 푼 후 정확한 경로에 넣었다면 다음 장의 예제를 실행할 수 있게 된다. 마음이 급해서 미리 확인하고 싶다면, 주피터 노트북을 실행해 `p2ch10_explore_data.ipynb`를 사용해볼 수 있다. 차례대로 진행하고 싶다면, 다음 10장에서 노트북을 좀 더 자세히 살펴보겠다. 데이터를 사용하기 전에 다운로드가 끝나길 바란다.

9.5 결론

프로젝트를 끝내기 위한 큰 걸음을 나아갔다. 아직 코드 한 줄도 구현하지 않았으니 대단한 성취를 이뤘다고 느끼기 어려울 수도 있다. 하지만 추후에 여러분의 프로젝트를 수행하려면 이 장에서 학습한 연구와 준비가 유용하게 사용될 것이다. 지금까지 우리는 다음 두 가지를 살펴봤다.

1. 폐암 진단 프로젝트를 큰 맥락에서 이해해봄
2. 2부 학습을 위한 프로젝트의 방향과 구조에 대한 개요 파악

실제 진전이 없었다고 느낀다면 그것이 함정임을 알아차리기 바란다. 프로젝트가 동작하는 전문 영역에 대한 이해를 높이는 것은 매우 중요하며, 이와 같이 마쳐둔 설계는 앞으로 프로젝트를 진행하며 훌륭하게 제값을 할 것이다. 다음 10장에서 데이터 로딩을 구현하기 시작하면서 바로 여기서 공부한 덕을 볼 것이다. 이 장에서는 코드 없이 주로 정보를 제공했으니 연습 문제는 다루지 않겠다.

9.6 핵심 요약

- 우리는 암으로 추정되는 결절을 발견하기 위해 데이터 로딩, 세그멘테이션, 그룹화, 분류, 결절 분석 및 진단으로 이어지는 다섯 단계의 접근 방식을 사용한다.
- 프로젝트를 작고 독립적인 하위 프로젝트로 나누면 각각의 하위 프로젝트를 좀 더 쉽게 설명할 수 있다. 이 책의 프로젝트와 목표가 다른 향후 프로젝트를 진행할 때는 지금과는 다른 방식의 접근법들이 더 적절할 수도 있다.
- CT 스캔은 대략적으로 3,200만 개의 복셀을 가진 3차원의 밀도 데이터 배열로서, 우리가 탐지하려는 결절보다 약 100만 배 정도 크다. 수행하려는 작업에 맞게 CT 스캔을 잘라내는 모델에 집중하면 훈련을 통해 꽤 괜찮은 결과를 더 쉽게 얻을 수 있다.

- 데이터 처리 루틴을 작성하기 전에 데이터 자체에 대해 잘 이해하면 데이터의 중요한 특징을 왜곡하거나 누락할 가능성을 줄일 수 있다. CT 스캔 데이터는 일반적으로 정방형의 복셀 데이터가 아니다. 현실 세계에서의 위치 정보를 배열의 인덱스로 변경하려면 별도의 변환 작업이 필요하다. CT 스캔의 밀도는 대략적으로 대상의 밀도와 일치하지만 특수한 단위를 사용한다.
- 프로젝트에서 사용하는 주요 개념을 이해하고 설계에서 이 부분이 잘 반영되게 하는 것은 매우 중요하다. 우리 프로젝트의 대부분은 폐 결절을 중심으로 문제를 풀어가게 된다. 폐 결절은 폐에 있는 작은 덩어리로서, 유사한 모양을 띠는 다른 많은 구조들과 함께 CT상에서 발견될 수 있다.
- 우리는 모델 훈련을 위해 LUNA 그랜드 챌린지 데이터를 사용한다. LUNA 데이터에는 CT 스캔 데이터뿐만 아니라, 분류와 그룹화를 위해 사람이 직접 레이블 작업을 한 출력값이 포함된다. 고품질의 데이터를 확보하는 것은 프로젝트를 성공시키는 데 큰 영향을 미친다.